

A forma da curva de juro real diz algo?

O juro real e os limites da previsão do prêmio de 10 anos do Tesouro IPCA+ (2010–2025)

Augusto Teixeira da Silva, Eduardo Vinicius Faleiro, Francisco de Paula Lemos e Lucas dos Santos
Santin

1 Introdução e objetivos

Quando o Tesouro Nacional emite um título Tesouro IPCA+ (NTN-B), ele remunera o investidor pela inflação acumulada mais uma taxa de juro real fixa. Esse juro real é o prêmio exigido para emprestar recursos ao governo por um determinado prazo, e seu valor difere entre prazos: o juro real de 2 anos não é o mesmo que o de 20 anos. O conjunto desses prêmios em diferentes prazos forma a chamada estrutura a termo, ou curva de juros, que possui uma forma própria. Quando os prazos mais longos pagam mais que os curtos, diz-se que a curva é normal; quando os curtos pagam mais que os longos, a curva está invertida.

No encerramento da amostra analisada (dezembro de 2025), o juro real de 10 anos encontrava-se elevado em relação aos quinze anos anteriores e, simultaneamente, a curva estava invertida. Essa combinação motivou a pergunta que dá título ao trabalho: a forma da curva (sua inclinação) carrega informação sobre o nível do juro real de 10 anos? Uma leitura clássica de mercado associa a inversão da curva à expectativa de que os juros não permanecerão altos, o que tornaria o momento descritivamente incomum.

O objetivo central é duplo. Primeiro, explorar ao máximo o conjunto de dados para caracterizar o comportamento do prêmio de juro real e suas relações com variáveis macroeconômicas (Selic, inflação e câmbio) e com a própria inclinação da curva. Segundo, modelar e prever o prêmio de 10 anos por meio de modelos de séries temporais, comparando o desempenho de uma abordagem puramente temporal (que utiliza apenas o passado da própria série) com o de uma regressão que incorpora as variáveis macro e a inclinação. Como objetivo secundário, de natureza interpretativa, avalia-se com ceticismo o que os dados efetivamente sustentam sobre a configuração atual da curva, distinguindo o que é medição do que é hipótese.

2 Materiais e métodos

2.1 Conjunto de dados

Construiu-se um painel mensal cobrindo janeiro de 2005 a dezembro de 2025, a partir de fontes públicas. As variáveis macroeconômicas - IPCA (inflação mensal, %), Selic (taxa acumulada no mês, %) e câmbio (dólar/real, PTAX venda, média mensal) - foram obtidas no Sistema Gerenciador de Séries Temporais (SGS) do Banco Central via pacote rbcbr. Os juros reais dos títulos Tesouro IPCA+ (NTN-B Principal) foram obtidos via pacote GetTDDData.

2.2 Interpolação em maturidade constante

Cada título tem vencimento fixo e, portanto, um prazo que diminui a cada dia; num dado mês raramente existe um título exatamente em 2, 5, 10 ou 20 anos, e o título mais próximo de um prazo de referência muda ao longo do tempo. Para obter séries comparáveis ao longo dos anos, interpolou-se linearmente a curva em prazos constantes de 2, 5, 10 e 20 anos a cada data, a partir dos títulos efetivamente negociados. Quando o prazo de referência caía fora do intervalo de títulos disponíveis, o valor foi registrado como ausente (NA) em vez de extrapolado, para não introduzir valores artificiais.

2.3 Tratamento e recorte

A inspeção de disponibilidade revelou que o vértice de 2 anos é raro (apenas 91 meses, com muitos intervalos vazios), tornando-o inviável; o vértice de 10 anos, ao contrário, é completo e contíguo (246 meses), sendo escolhido como variável-alvo. Os vértices de 5 e 20 anos têm boa cobertura. Por isso, a inclinação da curva foi definida como a diferença entre o prêmio de 20 anos e o de 5 anos ($\text{inclinacao} = \text{premio_20} - \text{premio_5}$), e não pela diferença teoricamente ideal de 20 menos 2 anos. A janela de análise foi fixada a partir de maio de 2010, primeiro mês em que a inclinação passa a existir.

Tabela 1 - Disponibilidade dos vértices

Vértice	Início	Fim	Meses válidos	Buracos internos
premio_2	Maio 2013	Dezembro 2025	91	61
premio_5	Maio 2010	Dezembro 2025	186	2
premio_10	Julho 2005	Dezembro 2025	246	0
premio_20	Março 2010	Dezembro 2025	170	20

2.4 Métodos

A análise exploratória incluiu estatísticas descritivas, histogramas, matriz de correlação e gráficos de dispersão. Por se tratar de séries com tendência, as correlações foram avaliadas tanto em nível quanto em primeiras diferenças, para distinguir relações genuínas de correlações espúrias decorrentes de tendências comuns. A estacionariedade foi avaliada pelos testes ADF e função ndiffs, mas também foi avaliada via inspeção visual dos outputs da função de autocorrelação (ACF) e da autocorrelação parcial (PACF). A modelagem da série-alvo empregou os modelos: ARIMA (automático via `auto.arima` e ajuste manual), suavização exponencial de Holt e o modelo ETS automático. Como concorrente, ajustou-se ainda uma regressão linear múltipla do prêmio de 10 anos sobre Selic, IPCA, câmbio e inclinação, com diagnóstico de resíduos via função `checkresiduals` (que usou o teste de autocorrelação dos resíduos de Breusch-Godfrey). A comparação de previsão usou separação treino/teste - treino até dezembro de 2024 e teste nos doze meses de 2025 - avaliada pelo erro absoluto médio (EAM/MAE). As análises foram realizadas no R, a sintaxe completa está no anexo.

3 Resultados e discussões


3.1 Caracterização das variáveis

No período, o prêmio de 10 anos teve média de 5,4% a.a. (mediana 5,6%), variando de 2,7% a 7,6% (**Tabela 2**), e sua distribuição apresenta mais de um aglomerado, sugerindo a passagem por patamares distintos (**Figura 1**). A inclinação teve média positiva (0,41) mas ampla variação (−0,76 a 1,88), tendo passado tanto por curva normal quanto invertida. O câmbio foi a variável de maior dispersão, refletindo a desvalorização do real ao longo dos quinze anos.

Tabela 2 - Estatísticas descritivas das variáveis (jan 2010 a dez 2025)

Variável	N	Média	Mediana	Desvio-padrão	Mínimo	Máximo
premio_10	188	5,41	5,63	1,22	2,66	7,64
inclinacao	166	0,41	0,40	0,60	-0,76	1,88
selic	188	0,78	0,83	0,28	0,13	1,28
ipca	188	0,47	0,44	0,36	-0,68	1,62
cambio	188	3,74	3,77	1,40	1,56	6,10

Figura 1 – Comportamento do premio_10 e da Inclinação no tempo



3.2 Correlações (r de Pearson): nível versus diferenças

Em nível, o prêmio de 10 anos correlaciona-se fortemente com a Selic (0,83) e negativamente com a inclinação (-0,81) (**Tabela 3**). Contudo, parte dessas correlações é espúria. Ao recalculer usando as variações mensais (removem a tendência comum e tendem a ser séries mais próximas de estacionárias), a correlação com a Selic praticamente desaparece (0,02), indicando que o vínculo em nível decorria de tendências comuns. Em contrapartida, o câmbio, sem correlação aparente em nível (0,01), revela associação nas variações (0,42): choques cambiais mensais parecem elevar o juro real exigido no mesmo mês. A relação com a inclinação encolhe, mas sobrevive (-0,38), sustentando que se trata de uma associação, ainda que modesta.

Tabela 3 – Correlação com o prêmio de 10 anos: nível vs. variações mensais

Variável	Correlação em nível	Correlação em variações
selic	0,83	0,02
inclinacao	-0,81	-0,38
cambio	0,01	0,42
ipca	-0,01	-0,04

3.3 A curva move-se em bloco

Testou-se a hipótese de que a Selic afetaria mais o vértice curto (premio_5) que o longo (premio_20) - o que explicaria a inversão. Os dados a rejeitaram: a variação da Selic quase não se correlaciona com a de qualquer vértice (0,02 a 0,04). Observou-se, porém, que os vértices se movem quase juntos nas variações (0,93 entre 5 e 10 anos; 0,95 entre 10 e 20 anos): a curva sobe e desce em bloco, e a inclinação é apenas a pequena diferença entre as pontas - o que explica seu caráter sutil.

3.4 A configuração “atual” em perspectiva histórica


Em dezembro de 2025, o prêmio de 10 anos situava-se no percentil 92,6 da amostra, a inclinação no percentil 1,8 - ou seja, a curva esteve mais invertida do que em 98% dos meses - e a Selic no percentil 98,9. É uma combinação extrema e pouco frequente: juro real alto e curva fortemente invertida ao mesmo tempo. Essa coincidência é consistente com a associação negativa já medida entre inclinação e nível (-0,38): curva invertida e juro alto tendem mesmo a andar juntos. O que esse retrato descreve, com segurança, é apenas a posição presente; o que ele significa para o futuro é uma questão à parte, retomada nas considerações finais.

3.5 Estacionariedade

A decomposição (**Figura 2**) mostrou domínio da tendência e sazonalidade desprezível, justificando o uso de ARIMA (e não SARIMA) e de Holt (e não Holt-Winters). A ACF da série em nível decaiu lentamente, sinal de forte persistência, característica de séries não-estacionárias. Os testes formais divergiram - o ADF não rejeitou a não-estacionariedade ($p = 0,58$), enquanto o ndiffs (KPSS) indicou zero diferenças - o que caracteriza uma série limítrofe, próxima de uma raiz unitária - uma série sem "âncora", diferente da temperatura de uma cidade, que sempre tende a voltar para uma média, ela se comporta mais como o saldo de uma conta, partindo sempre do último valor sem desfazer os movimentos passados. Após uma diferenciação - isto é, passando a analisar a variação de um mês

para o outro, em vez do valor absoluto -, a série torna-se claramente estacionária (ADF $p = 0,01$) e a ACF colapsa para dentro das bandas.

Figura 2 - Decomposição (mstl)



3.6 Modelos de série temporal

Na série completa, o `auto.arima` selecionou um $ARIMA(1,0,2)$ com coeficiente autorregressivo de 0,96, absorvendo a forte persistência sem diferenciar. Restrito ao treino, contudo, selecionou um $ARIMA(1,1,0)$, passando a diferenciar: a própria escolha da ordem muda conforme a amostra, evidência concreta do caráter limítrofe da série. Para confrontar a escolha automática com a leitura manual da série, ajustou-se também um $ARIMA(1,1,1)$ - ordem sugerida pela inspeção da ACF e da PACF da série diferenciada (que apontavam aproximadamente um termo autorregressivo e um de média móvel). Esse modelo manual mostrou-se praticamente idêntico ao automático, com termo de média móvel não significativo, indicando robustez: caminhos distintos (escolha automática e leitura visual dos gráficos) levaram essencialmente ao mesmo modelo. Em todos os casos, os resíduos comportaram-se como ruído (checkresiduals deu Ljung-Box não significativo).

3.7 Comparação de previsão (teste de 2025)

Pelo erro absoluto médio, o ranking foi ARIMA (0,18), ETS (0,30) e Holt (0,67). O ARIMA venceu por ser cuidadoso: projeta essencialmente o último nível observado (~7,2%), o que se mostrou adequado porque 2025 foi um ano de juro real estável. O Holt teve o pior desempenho por extrapolar a tendência de alta de 2023–2024, que não se confirmou. Vale a ressalva honesta de que nenhum modelo capturou as oscilações do realizado: o ARIMA acertou por estar no nível correto, não por antecipar os movimentos.

Figura 3 - Real vs previsões no teste 2025





Tabela 4 - Erro absoluto médio (EAM) na previsão do teste de 2025

Modelo	EAM (MAE)
ARIMA(1,1,0)	0,18
ETS	0,30
Holt	0,67
Regressão (variáveis macro + inclinação)	0,68

3.8 A inclinação ajuda? Regressão e o paradoxo explicar vs prever

Na regressão, a inclinação mostrou-se a segunda variável mais relevante (atrás apenas da Selic), com coeficiente de $-0,77$, confirmando a intuição de que a forma da curva carrega informação sobre o nível - resultado coerente com a associação que sobrevive nas variações ($-0,38$). O modelo explicou bem o presente (R^2 ajustado de $0,72$). Entretanto, o checkresiduals (teste de Breusch-Godfrey) acusou forte autocorrelação dos resíduos ($p < 2 \times 10^{-16}$), o que torna os p-valores otimistas e revela que a regressão, por ignorar a dinâmica temporal, viola a hipótese de independência dos resíduos. Cogitou-se aplicar um método de seleção automática de variáveis (forward com critério de Akaike). Provavelmente o método descartaria as duas variáveis não significativas (IPCA e câmbio), resultando num modelo mais enxuto e, possivelmente, com R^2 ajustado um pouco superior. Optou-se, porém, por reportar o modelo completo por transparência e porque essa simplificação não alteraria a conclusão central: o problema da regressão neste contexto não é o excesso de variáveis, e sim a autocorrelação dos resíduos já constatada - que nenhum método de seleção corrige. Na previsão, a regressão obteve EAM de $0,68$ - empatada com o pior modelo e $3,7$ vezes pior que o ARIMA -, ainda que tenha contado com vantagem: usou os valores reais das variáveis de 2025, que não estariam disponíveis no momento em que a previsão precisaria ser feita (final de 2024). Confirma-se que explicar não é prever: um bom ajuste do passado não garante boa previsão do futuro.

Figura 4 - Diagnóstico de resíduos da regressão



4 Considerações finais

O trabalho perguntou se a forma da curva de juro real ajuda a entender o prêmio de 10 anos. A resposta tem duas camadas. Para explicar o presente, sim: a inclinação é estatisticamente e economicamente relevante, e a relação resiste ao teste mais exigente das variações. Para prever o futuro, porém, essa informação não se converteu em ganho: um ARIMA simples, que usa apenas o passado da própria série, superou com folga a regressão repleta de variáveis macroeconômicas.

Do ponto de vista metodológico, três achados merecem destaque: a importância de avaliar correlações em diferenças, e não apenas em nível, para não confundir tendência comum com relação causal; o caráter limítrofe (quase raiz unitária) da série, que faz a própria escolha do modelo variar com a amostra; e a necessidade do teste de autocorrelação dos resíduos ao usar regressão em dados temporais.

Do ponto de vista econômico, o que os dados sustentam com segurança é apenas que dezembro de 2025 representa um extremo histórico da amostra - juro real elevado e curva fortemente invertida. A

leitura de que a inversão sinaliza queda futura dos juros é uma interpretação comum, mas é expectativa do mercado, não certeza: ela se apoia na hipótese das expectativas (segundo a qual os juros longos refletiriam a média dos juros curtos esperados) e deixa de lado o prêmio de prazo - a remuneração extra que o investidor cobra por travar seu dinheiro por mais tempo. Além disso, a própria modelagem mostrou que o nível futuro do juro real é, em larga medida, imprevisível. A curva, portanto, informa uma expectativa, não um destino.

Como limitação, registra-se que a regressão treinou com 22 meses a menos que o ARIMA, em razão de intervalos ausentes no vértice de 20 anos; o período de teste, contudo, é idêntico, e a diferença de desempenho é ampla o suficiente para que essa assimetria não explique o resultado. Extensões futuras poderiam incorporar modelos que tratem simultaneamente variáveis externas e dinâmica temporal.

5 Referências

BUENO, Rodrigo de Losso da Silveira. Econometria de séries temporais. 2. ed. São Paulo: Cengage Learning, 2012.

Obs.: Utilizado como base a respeito de correlação espúria - o risco de séries não-estacionárias parecerem correlacionadas apenas por compartilharem tendência - e da consequente necessidade de avaliar as relações em diferenças, não só em nível. Além de outras consultas breves.

6 Anexo com a sintaxe do R

```
# =====
# A FORMA DA CURVA DE JURO REAL E O PRÊMIO DE 10 ANOS (INE5649)
# Alvo: premio_10 = juro real de 10 anos (% a.a.).
# Dataset mensal (jan/2005 a dez/2025): data, ipca, selic, cambio,
# premio_2/5/10/20 (juro real % a.a. em prazos constantes, interpolados).
# =====

library(tidyverse)
## — Attaching core tidyverse packages —————
tidyverse 2.0.0 —
## ✓ dplyr      1.2.1      ✓ readr      2.2.0
## ✓ forcats    1.0.1      ✓ stringr    1.6.0
## ✓ ggplot2    4.0.3      ✓ tibble     3.3.1
## ✓ lubridate  1.9.5      ✓ tidyr      1.3.2
## ✓ purrr      1.2.2
## — Conflicts —————
tidyverse_conflicts() —
## ✖ dplyr::filter() masks stats::filter()
## ✖ dplyr::lag()     masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all
conflicts to become errors
  library(forecast)

# Lê o painel cru.
painel <- read_csv("../data/painel_final.csv")
## Rows: 252 Columns: 8
## — Column specification
##
## Delimiter: ","
## dbf  (7): ipca, selic, cambio, premio_2, premio_5, premio_10, premio_20
## date (1): data
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this
message.
  glimpse(painel)
## Rows: 252
## Columns: 8
## $ data      <date> 2005-01-01, 2005-02-01, 2005-03-01, 2005-04-01,
2005-05-01,...
## $ ipca      <dbl> 0.58, 0.59, 0.61, 0.87, 0.49, -0.02, 0.25, 0.17, 0.35,
0.75,...
## $ selic     <dbl> 1.38, 1.22, 1.53, 1.41, 1.50, 1.59, 1.51, 1.66, 1.50, 1.41,
...
## $ cambio    <dbl> 2.6930, 2.5978, 2.7047, 2.5792, 2.4528, 2.4135, 2.3735,
2.36...
## $ premio_2  <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,
...
```

```
## $ premio_5 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,
...
## $ premio_10 <dbl> NA, NA, NA, NA, NA, NA, 8.733787, 8.743471, 8.750395,
8.6409...
## $ premio_20 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,
...
# #####
#
# PARTE I – DADOS E EXPLORAÇÃO
# #####

# Cobertura de cada vértice (início, fim, válidos, buracos).
painel %>%
  pivot_longer(starts_with("premio_"), names_to = "vertice", values_to = "v") %>%
  group_by(vertice) %>%
  summarise(
    inicio = min(data[!is.na(v)]),
    fim = max(data[!is.na(v)]),
    n_validos = sum(!is.na(v)),
    buracos = sum(is.na(v) & data > min(data[!is.na(v)]) & data <
max(data[!is.na(v)])),
    .groups = "drop"
  )
## # A tibble: 4 × 5
##   vertice   inicio      fim      n_validos buracos
##   <chr>    <date>    <date>      <int>    <int>
## 1 premio_10 2005-07-01 2025-12-01      246      0
## 2 premio_2  2013-05-01 2025-12-01      91      61
## 3 premio_20 2010-03-01 2025-12-01     170      20
## 4 premio_5  2010-05-01 2025-12-01     186      2
# ACHADO: premio_10 completo (246 meses, 0 buracos); premio_2 ralo (91,
inviável); premio_5 e premio_20 boa cobertura.


# Recorta a janela (>= mai/2010) e cria inclinacao = premio_20 - premio_5.
analise <- painel %>%
  filter(data >= as.Date("2010-05-01")) %>%
  mutate(inclinacao = premio_20 - premio_5) %>%
  select(data, ipca, selic, cambio,
    premio_5, premio_10, premio_20, inclinacao)

# Resumo numérico das variáveis.
analise %>%
  select(premio_10, inclinacao, selic, ipca, cambio) %>%
  pivot_longer(everything(), names_to = "var", values_to = "v") %>%
  group_by(var) %>%
  summarise(
    n = sum(!is.na(v)), media = mean(v, na.rm = TRUE),
    mediana = median(v, na.rm = TRUE), dp = sd(v, na.rm = TRUE),
    min = min(v, na.rm = TRUE), max = max(v, na.rm = TRUE),
    .groups = "drop"
  )
## # A tibble: 5 × 7
##   var      n media mediana    dp    min    max
```

```
##   <chr>      <int> <dbl>   <dbl> <dbl>   <dbl> <dbl>
## 1 cambio      188 3.74    3.77  1.40    1.56  6.10
## 2 inclinacao  166 0.407   0.397 0.596 -0.762 1.88
## 3 ipca        188 0.465   0.435 0.362 -0.68  1.62
## 4 premio_10   188 5.41    5.63  1.22    2.66  7.64
## 5 selic       188 0.779   0.83  0.283  0.13  1.28
# ACHADO: premio_10 média 5,4% (mediana 5,6%; 2,7-7,6%); inclinacao média 0,41
# (-0,76 a 1,88); cambio 1,56-6,10; n=188 (inclinacao 166).

# Histograma + densidade de cada variável.
analise %>%
  select(premio_10, inclinacao, selic, ipca, cambio) %>%
  pivot_longer(everything(), names_to = "var", values_to = "valor") %>%
  ggplot(aes(valor)) +
  geom_histogram(aes(y = after_stat(density)), bins = 30,
    fill = "#7570b3", alpha = 0.5) +
  geom_density(color = "#1b9e77", linewidth = 0.8) +
  facet_wrap(~ var, scales = "free") +
  labs(title = "Distribuição de cada variável", x = NULL, y = NULL) +
  theme_minimal()
## Warning: Removed 22 rows containing non-finite outside the scale range
## (`stat_bin()`).
## Warning: Removed 22 rows containing non-finite outside the scale range
## (`stat_density()`).
```

Distribuição de cada variável



```
# ACHADO: premio_10 multimodal (massa ~4% e pico ~6%).
```

```
# Correlação em nível.
```


```
library(corrplot)
```

```
## corrplot 0.95 loaded
```

```

analise %>%
select(premio_10, inclinacao, selic, ipca, cambio) %>%
drop_na() %>%
cor() %>%
corrplot(method = "color", addCoef.col = "black",
          tl.col = "black", type = "upper")

```



ACHADO: premio_10, selic e cambio têm tendência; correlação em nível pode ser espúria.

Correlação em nível vs em diferenças mensais.

```
cols <- c("premio_10", "inclinacao", "selic", "ipca", "cambio")
```

```
analise %>% select(all_of(cols)) %>% drop_na() %>% cor() %>% round(2)
```

```
##          premio_10 inclinacao selic ipca cambio
## premio_10      1.00      -0.81  0.83 -0.01  0.01
## inclinacao     -0.81       1.00 -0.75  0.00  0.00
## selic          0.83      -0.75  1.00 -0.11 -0.06
## ipca          -0.01       0.00 -0.11  1.00 -0.03
## cambio         0.01       0.00 -0.06 -0.03  1.00
```

```
analise %>%
```

```
select(all_of(cols)) %>%
```

```
mutate(across(everything(), ~ . - lag(.))) %>%
```

```
drop_na() %>%
```


```
cor() %>% round(2)
```

```
##          premio_10 inclinacao selic ipca cambio
## premio_10      1.00      -0.38  0.02 -0.04  0.42
## inclinacao     -0.38       1.00 -0.03  0.21 -0.12
## selic          0.02      -0.03  1.00 -0.05  0.05
```

```
## ipca          -0.04      0.21 -0.05  1.00  -0.21
## cambio        0.42      -0.12  0.05 -0.21   1.00
# ACHADO (linha premio_10): selic 0,83->0,02 (espúria); cambio 0,01->0,42
# (aparece); inclinacao -0,81->-0,38 (sobrevive).

# Dispersão do premio_10 contra cada variável.
analise %>%
  select(premio_10, selic, inclinacao, ipca, cambio) %>%
  pivot_longer(-premio_10, names_to = "var", values_to = "valor") %>%
  ggplot(aes(valor, premio_10)) +
  geom_point(alpha = 0.4, color = "#7570b3") +
  geom_smooth(method = "lm", se = FALSE, color = "black", linewidth = 0.6) +
  facet_wrap(~ var, scales = "free_x") +
  labs(title = "Prêmio de 10 anos vs cada variável", y = "premio_10", x = NULL) +
  theme_minimal()
## `geom_smooth()` using formula = 'y ~ x'
## Warning: Removed 22 rows containing non-finite outside the scale range
## (`stat_smooth()`).
## Warning: Removed 22 rows containing missing values or values outside the
## scale range
## (`geom_point()`).
```

Prêmio de 10 anos vs cada variável



```
# ACHADO: selic positiva forte; inclinacao negativa nítida; ipca fraca; cambio
sem relação em nível.
```

```
# Variação da Selic vs variação de cada vértice.
```

```
analise %>%
  select(selic, premio_5, premio_10, premio_20) %>%
  mutate(across(everything(), ~ . - lag(.))) %>%
```

```

drop_na() %>%
cor() %>% round(2)
##           selic premio_5 premio_10 premio_20
## selic      1.00    0.04    0.02    0.04
## premio_5   0.04    1.00    0.93    0.81
## premio_10  0.02    0.93    1.00    0.95
## premio_20  0.04    0.81    0.95    1.00
# ACHADO: Selic ~0 com todos vértices (0,04/0,02/0,04); vértices entre si 0,93
# (5-10) e 0,95 (10-20).

# Série do alvo no tempo.
ggplot(analise, aes(data, premio_10)) +
  geom_line(color = "#1b9e77", linewidth = 0.6) +
  labs(title = "Prêmio de juro real de 10 anos (alvo)",
        x = NULL, y = "% a.a.") +
  theme_minimal()

```




```

# ACHADO: ondas longas (cai ~3%, sobe ~7,5%); alta persistência.

# Inclinação no tempo.
ggplot(analise, aes(data, inclinacao)) +
  geom_line(color = "#7570b3", linewidth = 0.6) +
  geom_hline(yintercept = 0, linetype = "dashed") +
  labs(title = "Inclinação da curva real (20a - 5a)",
        x = NULL, y = "pontos percentuais") +
  theme_minimal()

```



ACHADO: cruza o zero várias vezes; premio_10 alto <-> curva invertida.

Percentil do valor mais recente (dez/2025) na amostra 2010-2025.


```
ult <- function(x) tail(na.omit(x), 1)
analise %>%
  reframe(
    variavel = c("premio_10", "inclinacao", "selic", "cambio"),
    valor_hoje = round(c(ult(premio_10), ult(inclinacao),
                        ult(selic), ult(cambio)), 3),
    percentil = round(100 * c(
      mean(premio_10 <= ult(premio_10), na.rm = TRUE),
      mean(inclinacao <= ult(inclinacao), na.rm = TRUE),
      mean(selic <= ult(selic), na.rm = TRUE),
      mean(cambio <= ult(cambio), na.rm = TRUE)
    ), 1)
  )
## # A tibble: 4 × 3
##   variavel valor_hoje percentil
##   <chr>      <dbl>      <dbl>
## 1 premio_10    7.22      92.6
## 2 inclinacao  -0.723      1.8
## 3 selic        1.22     98.9
## 4 cambio      5.45     88.3
```

ACHADO: premio_10 percentil 92,6; inclinacao 1,8; selic 98,9. Dez/2025 = extremo (juro alto + curva muito invertida).

Objeto de série temporal mensal do alvo.


```
premio10_ts <- ts(analise$premio_10, frequency = 12, start = c(2010, 5))
```

```
# Decomposição tendência/sazonalidade/restante.  
autoplot(mstl(premio10_ts))
```




```
# ACHADO: tendência domina (~4,5); sazonalidade ~0,3 -> ARIMA, não SARIMA.
```

```
# Autocorrelação e lag.plot.  
acf(premio10_ts)
```



```
lag.plot(premio10_ts, lags = 9)
```



ACHADO: ACF começa ~0,97 e cai devagar -> não-estacionária; Lag 1 cola na diagonal.

```
# #####
#          PARTE II — MODELAGEM E PREVISÃO
# #####
```

Testes de estacionariedade (ADF vs KPSS via ndiffs).

```
library(tseries)
```

```
## Registered S3 method overwritten by 'quantmod':
```

```
##   method      from
```

```
## as.zoo.data.frame zoo
```

```
adf.test(premio10_ts)      # H0: NÃO é estacionária
```

```
##
```

```
## Augmented Dickey-Fuller Test
```

```
##
```

```
## data:  premio10_ts
```

```
## Dickey-Fuller = -1.9859, Lag order = 5, p-value = 0.5821
```

```
## alternative hypothesis: stationary
```

```
ndiffs(premio10_ts)      # usa KPSS -> H0 oposta: É estacionária
```


```
## [1] 0
```

ACHADO: ADF p=0,58 (não rejeita); ndiffs=0. Série borderline (quase raiz unitária).


Primeira diferença e seus diagnósticos.

```
dif1 <- diff(premio10_ts)
```

```
autoplot(dif1) +  
  labs(title = "Prêmio 10 anos - 1ª diferença", x = NULL, y = NULL) +  
  theme_minimal()
```




```
acf(dif1)
```



```
adf.test(dif1)
```


```
## Warning in adf.test(dif1): p-value smaller than printed p-value
##
## Augmented Dickey-Fuller Test
##
## data: dif1
## Dickey-Fuller = -4.3779, Lag order = 5, p-value = 0.01
## alternative hypothesis: stationary
# ACHADO: diferenciar 1x resolve; ADF p=0,01 -> estacionária.
# PACF da série diferenciada (ordens do ARIMA).
pacf(dif1)
```



```
# ACHADO: só lag 1 fura -> ~1 termo AR; palpite ARIMA(1,1,1).

# auto.arima na série inteira + checagem de resíduos.
mod_auto <- auto.arima(premio10_ts, seasonal = FALSE)
summary(mod_auto)
## Series: premio10_ts
## ARIMA(1,0,2) with non-zero mean
##
## Coefficients:
##          ar1      ma1      ma2      mean
##          0.9603  0.2796  0.1452  5.7074
## s.e.      0.0206  0.0732  0.0787  0.5893
##
## sigma^2 = 0.0626: log likelihood = -5.93
## AIC=21.86   AICc=22.19   BIC=38.04
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
```

```
## Training set -0.00520934 0.2475212 0.1851235 -0.379786 3.727177 0.1799189
## ACF1
## Training set 0.007207401
checkresiduals(mod_auto) # Ljung-Box
```



```
##
## Ljung-Box test
##
## data: Residuals from ARIMA(1,0,2) with non-zero mean
## Q* = 18.661, df = 21, p-value = 0.6069
##
## Model df: 3. Total lags used: 24
# ACHADO: ARIMA(1,0,2), ar1=0,96; Ljung-Box p=0,61 -> resíduos OK.

# Split treino (<= dez/2024) / teste (2025) e ARIMA só no treino.
treino <- window(premio10_ts, end = c(2024, 12))
teste <- window(premio10_ts, start = c(2025, 1))

mod_auto_tr <- auto.arima(treino, seasonal = FALSE)
summary(mod_auto_tr)
## Series: treino
## ARIMA(1,1,0)
##
## Coefficients:
## ar1
## 0.2677
## s.e. 0.0730
##
## sigma^2 = 0.06504: log likelihood = -8.73
## AIC=21.47 AICc=21.54 BIC=27.8
```

```
##
## Training set error measures:
##           ME          RMSE          MAE          MPE          MAPE          MASE
## Training set 0.003015342 0.2535748 0.1890058 -0.05228778 3.839902 0.1862236
##           ACF1
## Training set -0.009076257
prev_auto <- forecast(mod_auto_tr, h = length(teste))
# ACHADO: no treino escolhe ARIMA(1,1,0) (d=1); muda de ideia -> confirma
borderline.

# ARIMA(1,1,1) manual.
mod_d1 <- Arima(treino, order = c(1, 1, 1))
summary(mod_d1)
## Series: treino
## ARIMA(1,1,1)
##
## Coefficients:
##          ar1          ma1
##       0.3665   -0.1058
## s.e.  0.2306    0.2436
##
## sigma^2 = 0.06534: log likelihood = -8.64
## AIC=23.28   AICc=23.42   BIC=32.77
##
## Training set error measures:
##           ME          RMSE          MAE          MPE          MAPE          MASE
## Training set 0.003030462 0.2534362 0.1887762 -0.04565613 3.840174 0.1859974
##           ACF1
## Training set -0.0005874377
prev_d1 <- forecast(mod_d1, h = length(teste))
# ACHADO: ma1=-0,11 não-significativo; equivale ao (1,1,0) automático.

# ARIMA automático vs real (2025).
autoplot(prev_auto) +
  autolayer(teste, series = "Real") +
  labs(title = "ARIMA automático vs real (2025)", x = NULL, y = "% a.a.") +
  theme_minimal()
```

ARIMA automático vs real (2025)



ACHADO: previsão ~reta em 7,2; real 2025 colado; Leque de confiança abre (5 a 9).

Concorrentes de suavização exponencial.

```
mod_holt <- holt(treino, h = length(teste))
mod_ets <- forecast(ets(treino), h = length(teste))
prev_holt <- mod_holt
prev_ets <- mod_ets
```

Tabela de erros (MAE no teste de 2025).

```
comp <- tibble(
  data = seq(as.Date("2025-01-01"), by = "month", length.out = length(teste)),
  Real = as.numeric(teste),
  ARIMA = as.numeric(prev_auto$mean),
  Holt = as.numeric(prev_holt$mean),
  ETS = as.numeric(prev_ets$mean)
)
```

```
eam <- function(yreal, yprev) mean(abs(yreal - yprev))
```

```
resultados <- tibble(
  Modelo = c("ARIMA(1,1,0)", "Holt", "ETS"),
  MAE = c(eam(comp$Real, comp$ARIMA),
          eam(comp$Real, comp$Holt),
          eam(comp$Real, comp$ETS))
) %>% arrange(MAE)
```


```
resultados
```

```
## # A tibble: 3 × 2
```

```
##   Modelo      MAE
```

```
## <chr>      <dbl>
## 1 ARIMA(1,1,0) 0.181
## 2 ETS         0.301
## 3 Holt        0.672
# ACHADO: ARIMA 0,18 < ETS 0,30 < Holt 0,67.

# Real vs todas as previsões.
comp %>%
  pivot_longer(-data, names_to = "serie", values_to = "valor") %>%
  ggplot(aes(data, valor, color = serie)) +
  geom_line(linewidth = 0.7) +
  labs(title = "Real vs previsões – teste 2025",
       x = NULL, y = "% a.a.", color = NULL) +
  theme_minimal() + theme(legend.position = "bottom")
```




ACHADO: Holt dispara (~8,7); ETS sobe amortecido; ARIMA ~reta em 7,2; ninguém capturou os solavancos.

Regressão concorrente com a inclinação.


```
analise_tr <- analise %>% filter(data <= as.Date("2024-12-01"))
analise_te <- analise %>% filter(data >= as.Date("2025-01-01"))

mod_reg <- lm(premio_10 ~ selic + ipca + cambio + inclinacao, data = analise_tr)
summary(mod_reg)
##
## Call:
## lm(formula = premio_10 ~ selic + ipca + cambio + inclinacao,
##     data = analise_tr)
##
## Residuals:
```

```
##      Min      1Q   Median      3Q      Max
## -1.46652 -0.32243 -0.04762  0.34950  1.45210
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.926756   0.291262  13.482 < 2e-16 ***
## selic        2.172947   0.259972   8.358 4.13e-14 ***
## ipca         0.136004   0.129111   1.053  0.294
## cambio      -0.009558   0.033081  -0.289  0.773
## inclinacao  -0.769231   0.118689  -6.481 1.25e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5765 on 149 degrees of freedom
## (22 observations deleted due to missingness)
## Multiple R-squared:  0.7269, Adjusted R-squared:  0.7196
## F-statistic: 99.16 on 4 and 149 DF,  p-value: < 2.2e-16
library(car)
## Loading required package: carData
##
## Attaching package: 'car'
##
## The following object is masked from 'package:dplyr':
##
##     recode
##
## The following object is masked from 'package:purrr':
##
##     some
Anova(mod_reg)
## Anova Table (Type II tests)
##
## Response: premio_10
##              Sum Sq Df F value    Pr(>F)
## selic        23.217  1 69.8624 4.133e-14 ***
## ipca          0.369  1  1.1096   0.2939
## cambio        0.028  1  0.0835   0.7730
## inclinacao  13.959  1 42.0040 1.255e-09 ***
## Residuals    49.515 149
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## # ACHADO: inclinacao -0,77 (F=42, 2ª mais forte); selic +2,17 (F=70); ipca e
## cambio não-sig em nível; R²aj=0,72.
##
## Diagnóstico dos resíduos.
par(mfrow = c(2, 2)); plot(mod_reg); par(mfrow = c(1, 1))
```



```
checkresiduals(mod_reg)
```



```
##
## Breusch-Godfrey test for serial correlation of order up to 10
##
```

```
## data: Residuals
## LM test = 115.58, df = 10, p-value < 2.2e-16
# ACHADO: Breusch-Godfrey  $p < 2e-16$  -> autocorrelação fortíssima; p-valores do OLS
otimistas.

# Previsão da regressão em 2025.
prev_reg <- predict(mod_reg, newdata = analyse_te)
eam(analise_te$premio_10, prev_reg)
## [1] 0.6805638
# ACHADO: MAE regressão = 0,68 (empata Holt, 3,7x pior que ARIMA 0,18). Explicar
!= prever.

# #####
#
# PARTE III – CONCLUSÃO
# #####
# - Inclinação ajuda a EXPLICAR (2ª variável mais forte, sobrevive nas variações),
mas não a PREVER: ARIMA simples venceu.
# - dez/2025 = extremo da amostra (juízo real no topo, curva fortemente invertida);
Leitura "vai cair" é hipótese, não fato.
```