

analise_final.R

chicoz0

2026-06-25

```
# =====  
# A FORMA DA CURVA DE JURO REAL E O PRÊMIO DE 10 ANOS  
# Uma análise de séries temporais (INE5649)  
# =====  
#  
# A HISTÓRIA QUE ESTE TRABALHO CONTA  
  
# Quando o governo brasileiro emite um título Tesouro IPCA+ (NTN-B), ele  
# promete pagar a inflação MAIS um juro real fixo. Esse "juro real" é o  
# prêmio que o investidor exige para emprestar ao governo por um prazo.  
# Ele muda todo dia e muda de forma diferente para cada prazo: o juro real  
# de 2 anos não é o mesmo que o de 20 anos. A "curva" formada por esses  
# prêmios tem uma FORMA – às vezes sobe com o prazo (curva normal - onde  
# títulos de curto prazo pagam menos que os de longo prazo), às vezes  
# inverte (títulos de curto prazo pagam mais que os de longo).  
#  
# A PERGUNTA CENTRAL: a FORMA da curva (sua inclinação) ajuda a entender e  
# a prever o nível do juro real de 10 anos? E um modelo com variáveis  
# macro (Selic, inflação, câmbio) + essa inclinação prevê melhor que um  
# modelo de série temporal que só olha o passado do próprio juro?  
#  
# UMA SEGUNDA CAMADA (leitura econômica): no fim de 2025 o juro real de 10  
# anos está alto E a curva está invertida. Uma leitura clássica diz que  
# curva invertida reflete a EXPECTATIVA do mercado de que os juros não vão  
# durar. Este trabalho investiga, com ceticismo, se a configuração atual é  
# de fato um extremo histórico – e o que os dados HONESTAMENTE permitem (e  
# não permitem) concluir sobre isso.  
#  
# O ALVO: premio_10 = juro real de 10 anos (% ao ano).  
#  
# O SPOILER (que vamos demonstrar): a inclinação É relevante para explicar  
# o prêmio – mas a regressão, apesar de explicar bem ( $R^2=0,72$ ), PREVÊ pior  
# que um ARIMA simples. A moral: explicar e prever são coisas diferentes.  
#  
# O DATASET é assim (mês a mês, jan/2005 a dez/2025):  
# data      -> primeiro dia de cada mês  
# ipca      -> inflação mensal medida pelo IPCA (% no mês)  
# selic     -> taxa básica de juros acumulada no mês (% no mês)  
# cambio    -> dólar/real (PTAX venda, média do mês)  
# premio_2/5/10/20 -> juro real (% a.a.) do Tesouro IPCA+ em prazos fixos  
#                      de 2, 5, 10 e 20 anos.  
#                      Valores interpolados = estimados de valores vizinhos  
#                      que temos.  
#                      POR QUE INTERPOLAR? Cada título tem uma data de
```

```

# vencimento fixa (ex.: 2035, 2045). Num dia qualquer,
# o prazo que falta até o vencimento é um número
# quebrado – títulos com prazo de 9,8 anos ou 9,3 anos;
# raramente existe um título exatamente com prazo de
# 2, 5, 10 ou 20 anos exatos. Além disso, o título
# mais próximo de "10 anos" muda com o tempo (conforme
os
# títulos encurtam e novos são emitidos). Para ter uma
# série comparável ao longo dos anos, interpolamos a
# curva em PRAZOS CONSTANTES: a cada mês, estimamos
qual
# seria o juro de um título de exatamente 2, 5, 10 e 20
# anos, a partir dos títulos que de fato existem
naquele
# dia.
# =====

```

```
library(tidyverse)
```

```

## — Attaching core tidyverse packages —————
tidyverse 2.0.0 —
## ✓ dplyr      1.2.1      ✓ readr      2.2.0
## ✓ forcats   1.0.1      ✓ stringr    1.6.0
## ✓ ggplot2    4.0.3      ✓ tibble     3.3.1
## ✓ lubridate 1.9.5      ✓ tidyr      1.3.2
## ✓ purrr     1.2.2
## — Conflicts —————
tidyverse_conflicts() —
## ✗ dplyr::filter() masks stats::filter()
## ✗ dplyr::lag()     masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all
conflicts to become errors

```

```
library(forecast)
```

```

# --- Leitura do painel cru (gerado pelo script de coleta) ---
painel <- read_csv("../data/painel_final.csv")

```

```

## Rows: 252 Columns: 8
## — Column specification

```

```

## Delimiter: ","
## dbl (7): ipca, selic, cambio, premio_2, premio_5, premio_10, premio_20
## date (1): data
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this
message.

```

```
glimpse(painel)
```

```
## Rows: 252
## Columns: 8
## $ data      <date> 2005-01-01, 2005-02-01, 2005-03-01, 2005-04-01,
2005-05-01,...
## $ ipca      <dbl> 0.58, 0.59, 0.61, 0.87, 0.49, -0.02, 0.25, 0.17, 0.35,
0.75,...
## $ selic     <dbl> 1.38, 1.22, 1.53, 1.41, 1.50, 1.59, 1.51, 1.66, 1.50,
1.41, ...
## $ cambio    <dbl> 2.6930, 2.5978, 2.7047, 2.5792, 2.4528, 2.4135, 2.3735,
2.36...
## $ premio_2  <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,
NA, ...
## $ premio_5  <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,
NA, ...
## $ premio_10 <dbl> NA, NA, NA, NA, NA, NA, NA, 8.733787, 8.743471, 8.750395,
8.6409...
## $ premio_20 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,
NA, ...
```

```
# #####
#                               PARTE I – DADOS E EXPLORAÇÃO
# #####
```

```
# 1. PRIMEIRA INVESTIGAÇÃO: o dado existe de verdade?
```

```
# Antes de escolher variáveis, vemos quanto de cada vértice temos de fato.
# A interpolação só é honesta quando há títulos perto do prazo; quando não
# há, o valor seria inventado (por isso, na coleta, viram NA em vez de
chute).
```

```
painel %>%
  pivot_longer(starts_with("premio_"), names_to = "vertice", values_to = "v")
%>%
  group_by(vertice) %>%
  summarise(
    inicio   = min(data[!is.na(v)]),
    fim      = max(data[!is.na(v)]),
    n_validos = sum(!is.na(v)),
    buracos  = sum(is.na(v) & data > min(data[!is.na(v)]) & data <
max(data[!is.na(v)])),
    .groups = "drop"
  )
```

```
## # A tibble: 4 × 5
##   vertice   inicio      fim      n_validos buracos
##   <chr>    <date>    <date>      <int>    <int>
## 1 premio_10 2005-07-01 2025-12-01     246      0
## 2 premio_2  2013-05-01 2025-12-01      91     61
## 3 premio_20 2010-03-01 2025-12-01     170     20
## 4 premio_5  2010-05-01 2025-12-01     186      2
```

```

# ACHADO (lendo a tabela acima):
# - premio_10: completo e contíguo (246 meses, 0 buracos) -> candidato natural a ALVO.
# - premio_2 : ralo demais (91 meses, com muitos buracos no meio) -> inviável.
# - premio_5 e premio_20: boa cobertura, com alguns buracos no premio_20.
# Conclusão parcial: analisar o premio de 2 anos não se sustenta; a inclinação terá de ser construída a partir dos vértices bem cobertos (5 e 20 anos).

# 2. DATASET DE TRABALHO

# A inclinação só existe a partir de mai/2010, então recortamos a janela.
# A inclinacao resume a FORMA da curva num número (positivo = curva normal, # negativo = curva invertida).
analise <- painel %>%
  filter(data >= as.Date("2010-05-01")) %>%
  mutate(inclinacao = premio_20 - premio_5) %>%
  select(data, ipca, selic, cambio,
         premio_5, premio_10, premio_20, inclinacao)

# 3. CONHECENDO CADA VARIÁVEL (descritivas e distribuições)

# --- Resumo numérico (os "marcos" de cada variável) ---
analise %>%
  select(premio_10, inclinacao, selic, ipca, cambio) %>%
  pivot_longer(everything(), names_to = "var", values_to = "v") %>%
  group_by(var) %>%
  summarise(
    n = sum(!is.na(v)), media = mean(v, na.rm = TRUE),
    mediana = median(v, na.rm = TRUE), dp = sd(v, na.rm = TRUE),
    min = min(v, na.rm = TRUE), max = max(v, na.rm = TRUE),
    .groups = "drop"
  )

## # A tibble: 5 × 7
##   var          n media mediana    dp    min    max
##   <chr>      <int> <dbl>   <dbl> <dbl> <dbl> <dbl>
## 1 cambio    188  3.74    3.77  1.40  1.56  6.10
## 2 inclinacao 166  0.407   0.397 0.596 -0.762  1.88
## 3 ipca      188  0.465   0.435 0.362 -0.68  1.62
## 4 premio_10 188  5.41    5.63  1.22  2.66  7.64
## 5 selic     188  0.779   0.83  0.283  0.13  1.28

# ACHADO:
# - premio_10: média 5,4% (mediana 5,6%), variando de 2,7% a 7,6% no período.
#   A mediana acima da média sugere leve assimetria à esquerda (alguns meses de juro baixo "puxam" a média para baixo).
# - inclinacao: média 0,41, mas com amplitude grande (-0,76 a 1,88) – ou seja,
#   passou tanto por curva invertida quanto bem inclinada. Em média positiva

```

```
# (curva normal foi o estado mais comum no período).
# - selic e ipca: as de MENOR dispersão relativa, oscilando em faixas
# estreitas.
# - cambio: o maior espalhamento (1,56 a 6,10) – reflexo da desvalorização do
# real ao longo dos 15 anos.
# - n: premio_10/selic/ipca/cambio têm 188 meses; a inclinacao só 166 (herda
# os buracos do premio_20), como esperado.
```

```
# --- Distribuição (a forma de cada variável) ---
```


```
analise %>%
```

```
  select(premio_10, inclinacao, selic, ipca, cambio) %>%
  pivot_longer(everything(), names_to = "var", values_to = "valor") %>%
  ggplot(aes(valor)) +
  geom_histogram(aes(y = after_stat(density)), bins = 30,
                 fill = "#7570b3", alpha = 0.5) +
  geom_density(color = "#1b9e77", linewidth = 0.8) +
  facet_wrap(~ var, scales = "free") +
  labs(title = "Distribuição de cada variável", x = NULL, y = NULL) +
  theme_minimal()
```

```
## Warning: Removed 22 rows containing non-finite outside the scale range
## (`stat_bin()`).
```

```
## Warning: Removed 22 rows containing non-finite outside the scale range
## (`stat_density()`).
```

Distribuição de cada variável



```
# A distribuição do premio_10 não é um sino único: aparece mais de um  
# aglomerado (massa perto de ~4% e pico em ~6%), sugerindo que a série  
# passou por patamares distintos ao longo do período.
```

```
# 4. QUEM ANDA COM QUEM (correlações)
```

```
# --- Correlação em NÍVEL (e a armadilha que ela esconde) ---
```

```
library(corrplot)
```

```
## corrplot 0.95 loaded
```


```
analise %>%
```

```
  select(premio_10, inclinacao, selic, ipca, cambio) %>%
```

```
  drop_na() %>%
```

```
  cor() %>%
```

```
  corrplot(method = "color", addCoef.col = "black",  
           tl.col = "black", type = "upper")
```



```
# Atenção a uma armadilha. premio_10, selic e cambio têm tendência: sobem e  
# descem em ondas longas. Duas séries assim acusam correlação alta só por  
# andarem na mesma direção no tempo, mesmo sem relação de verdade entre elas  
# – é o que se chama de correlação ESPÚRIA (falsa, enganosa).  
# Exemplo clássico: o número de afogamentos e a venda de sorvete sobem juntos  
# no verão, mas um não causa o outro – quem move os dois é o calor.  
# Para separar o real do espúrio, olhamos as VARIAÇÕES mês a mês (próximo  
# bloco): se a correlação sobrevive nas variações, é relação genuína; se  
# desaparece, era só a tendência comum enganando.
```

```

# --- Teste anti-espúrio: nível vs diferenças ---
cols <- c("premio_10", "inclinacao", "selic", "ipca", "cambio")

# (a) Em níveis – pode estar contaminada pela tendência comum
analise %>% select(all_of(cols)) %>% drop_na() %>% cor() %>% round(2)

##          premio_10 inclinacao selic  ipca cambio
## premio_10      1.00      -0.81  0.83 -0.01   0.01
## inclinacao     -0.81       1.00 -0.75  0.00   0.00
## selic           0.83      -0.75  1.00 -0.11  -0.06
## ipca           -0.01       0.00 -0.11  1.00  -0.03
## cambio          0.01       0.00 -0.06 -0.03  1.00

# (b) Em diferenças mensais – relação entre as VARIAÇÕES
analise %>%
  select(all_of(cols)) %>%
  mutate(across(everything(), ~ . - lag(.))) %>%
  drop_na() %>%
  cor() %>% round(2)

##          premio_10 inclinacao selic  ipca cambio
## premio_10      1.00      -0.38  0.02 -0.04   0.42
## inclinacao     -0.38       1.00 -0.03  0.21  -0.12
## selic           0.02      -0.03  1.00 -0.05   0.05
## ipca           -0.04       0.21 -0.05  1.00  -0.21
## cambio          0.42      -0.12  0.05 -0.21  1.00

# ACHADO (um dos centrais do trabalho) – olhando a linha do premio_10:
# - selic:      0,83 -> 0,02. A correlação forte EVAPORA nas variações. Era
#              ESPÚRIA: premio e Selic só pareciam andar juntos por terem
#              tendências de longo prazo parecidas. Mês a mês, não casam.
#              (Se tivéssemos confiado no nível, contaríamos história
#              errada.)
# - cambio:     0,01 -> 0,42. O OPOSTO: uma relação INVISÍVEL em nível
#              APARECE
#              nas variações. Quando o real apanha num mês, o juro real
#              exigido sobe naquele mês (reação de curto prazo a choque).
#              Isso contradiz a regressão em nível (onde câmbio deu p=0,77).
# - inclinacao: -0,81 -> -0,38. ENCOLHE mas SOBREVIVE. Parte era tendência
#              comum, mas resta relação real. A associação que sustenta a
#              tese central NÃO é miragem – é mais modesta, e genuína.

# --- Dispersão do alvo contra cada variável ---
analise %>%
  select(premio_10, selic, inclinacao, ipca, cambio) %>%
  pivot_longer(-premio_10, names_to = "var", values_to = "valor") %>%
  ggplot(aes(valor, premio_10)) +
  geom_point(alpha = 0.4, color = "#7570b3") +
  geom_smooth(method = "lm", se = FALSE, color = "black", linewidth = 0.6) +

```

```


facet_wrap(~ var, scales = "free_x") +
  labs(title = "Prêmio de 10 anos vs cada variável", y = "premio_10", x =
NULL) +
  theme_minimal()

## `geom_smooth()` using formula = 'y ~ x'

## Warning: Removed 22 rows containing non-finite outside the scale range
## (`stat_smooth()`).

## Warning: Removed 22 rows containing missing values or values outside the
scale range
## (`geom_point()`).

```



```

# ACHADOS:
# Corroborar com os anteriores.
# Cada reta preta é o ajuste linear do prêmio contra a variável.
# - selic: nuvem apertada e inclinada -> relação positiva forte (a mais clara).
# - inclinacao: reta descendente nítida -> relação negativa (a tese principal que temos).
# - ipca: reta quase plana, pontos espalhados -> relação fraca.
# - cambio: reta horizontal, sem padrão -> sem relação linear em nível.
# Prévia do que a regressão vai testar: selic e inclinacao puxam a curva do juro real; ipca e cambio não.

```

```

# --- Por que a curva inverte? Cada vértice vs a Selic ---

```

```
# Hipótese testada: a Selic mexeria MAIS no premio_5 do que no premio_20.  
analise %>%
```

```
  select(selic, premio_5, premio_10, premio_20) %>%  
  mutate(across(everything(), ~ . - lag(.))) %>%  
  drop_na() %>%  
  cor() %>% round(2)
```

```
##           selic premio_5 premio_10 premio_20  
## selic      1.00      0.04      0.02      0.04  
## premio_5   0.04      1.00      0.93      0.81  
## premio_10  0.02      0.93      1.00      0.95  
## premio_20  0.04      0.81      0.95      1.00
```

```
# ACHADO: a hipótese não colou. A variação da Selic quase não se mexe junto  
# com a de nenhum vértice (0,04 / 0,02 / 0,04), e não cai conforme vai do  
# premio_5 ao premio_20 – ou seja, ela não "bate mais" no de 5 anos.  
# Em compensação, apareceu outra coisa: premio_5, premio_10 e premio_20 sobem  
# e descem quase juntos (0,93 entre 5 e 10; 0,95 entre 10 e 20). A curva se  
# move em bloco, e a inclinação é só a sobrinha que sobra entre as pontas –  
# daí ela ser uma variável tão sutil.  
# Um palpite pra explicar (não testado aqui): a Selic é definida pelo Copom  
# em saltos, em datas certas, enquanto os prêmios são de mercado e se mexem  
# todo dia, antecipando o Copom. Por isso as variações mês a mês não casam.
```

```
# 5. A SÉRIE NO TEMPO + ONDE ESTAMOS HOJE (leitura da curva)
```


```
# --- O alvo (premio_10) ao longo do tempo ---  
ggplot(analise, aes(data, premio_10)) +  
  geom_line(color = "#1b9e77", linewidth = 0.6) +  
  labs(title = "Prêmio de juro real de 10 anos (alvo)",  
        x = NULL, y = "% a.a.") +  
  theme_minimal()
```

Prêmio de juro real de 10 anos (alvo)



ACHADO: não há UMA tendência, e sim ONDAS LONGAS de vários anos – cai a
~3% (2012-13, 2019-20), sobe a ~7,5% (2015-16, 2024-25), em ciclos de
política monetária e risco fiscal. A linha é "lisa": cada mês é quase igual
ao anterior e a série leva anos para mudar de patamar. Isso se chama alta
PERSISTÊNCIA – e vai reaparecer na ACF e no ARIMA mais à frente.

```
# --- A inclinação ao longo do tempo ---  
ggplot(analise, aes(data, inclinacao)) +  
  geom_line(color = "#7570b3", linewidth = 0.6) +  
  geom_hline(yintercept = 0, linetype = "dashed") +  
  labs(title = "Inclinação da curva real (20a - 5a)",  
        x = NULL, y = "pontos percentuais") +  
  theme_minimal()
```



ACHADO: a inclinação cruza o zero várias vezes. E contraste com o gráfico anterior: quando o premio_10 está BAIXO, a inclinação tende a POSITIVA; quando o premio_10 está ALTO (2024-25), a curva INVERTE. Nível e forma se movem em sentidos opostos – coerente com a correlação negativa (-0,38).

*# --- Onde estamos HOJE, na história da amostra (2010-2025) ---
Percentil = fração de meses com valor <= o valor mais recente (dez/2025).
IMPORTANTE: "história" = nossa janela 2010-2025, NÃO "todos os tempos".*

```
ult <- function(x) tail(na.omit(x), 1)
analise %>%
  reframe(
    variavel = c("premio_10", "inclinacao", "selic", "cambio"),
    valor_hoje = round(c(ult(premio_10), ult(inclinacao),
                        ult(selic), ult(cambio)), 3),
    percentil = round(100 * c(
      mean(premio_10 <= ult(premio_10), na.rm = TRUE),
      mean(inclinacao <= ult(inclinacao), na.rm = TRUE),
      mean(selic <= ult(selic), na.rm = TRUE),
      mean(cambio <= ult(cambio), na.rm = TRUE)
    ), 1)
  )

## # A tibble: 4 × 3
##   variavel  valor_hoje percentil
##   <chr>      <dbl>     <dbl>
## 1 premio_10      7.22      92.6
```

```
## 2 inclinacao      -0.723      1.8
## 3 selic           1.22       98.9
## 4 cambio          5.45       88.3
```

```
# ACHADO ROBUSTO:
```

```
# - premio_10 no percentil 92,6 (juro real alto vs os últimos 15 anos).
# - inclinacao no percentil 1,8 (curva mais invertida que em 98% da amostra).
# - selic no percentil 98,9 (aperto monetário quase máximo).
# Dez/2025 é um EXTREMO CONJUNTO RARO: juro alto + curva muito invertida.
#
```

```
# LEITURA DA CURVA:
```

```
# - O que é MEDIÇÃO: estamos num extremo histórico da amostra, e a
#   inclinação tem associação negativa real (porém modesta) com o nível.
# - O que é INTERPRETAÇÃO (hipótese, não medida): a curva invertida é lida
#   como o mercado ESPERANDO que o juro alto não perdure. Mas isso supõe a
#   hipótese das expectativas e ignora o prêmio de prazo – é leitura, não
#   fato.
# - HUMILDADE NECESSÁRIA: expectativa do mercado NÃO é certeza. E, como o
#   ARIMA vai mostrar, o nível futuro é largamente imprevisível (quase
#   passeio aleatório). Logo, o robusto é só "estamos num extremo"; qualquer
#   afirmação sobre "vai cair" extrapolaria o que os dados sustentam.
```


```
# --- Diagnóstico da série para a modelagem ---
```

```
# Objeto de série temporal mensal do alvo.
```

```
premio10_ts <- ts(analise$premio_10, frequency = 12, start = c(2010, 5))
```

```
# Decomposição em tendência / sazonalidade / restante.
```

```
autoplot(mstl(premio10_ts))
```




ACHADO CRUCIAL: a tendência domina (~4,5 pontos); a "sazonalidade" é
minúscula (~0,3) e sem padrão de calendário aparente.
CONSEQUÊNCIA: usaremos ARIMA (não SARIMA) e Holt (não Holt-Winters).
Juro de mercado não tem "mês de alta".


Autocorrelação: o passado prevê o presente?

`acf(premio10_ts)`

Series premio10_ts



```
lag.plot(premio10_ts, lags = 9)
```



```

# ACHADO:
# a ACF começa em ~0,97 e CAI DEVAGAR -> assinatura de série
# NÃO-ESTACIONÁRIA (o nível vagueia).
# O lag.plot confirma: no lag 1 os pontos quase colam na diagonal
# (persistência altíssima).

# #####
#             PARTE II – MODELAGEM E PREVISÃO
# #####

# 6. A SÉRIE É ESTACIONÁRIA? (o ponto sutil)

# (estacionária = série estável, que oscila em torno de uma média fixa em vez
# de vagar entre patamares ao longo do tempo)

# --- Os testes formais (ADF vs KPSS) ---
library(tseries)

## Registered S3 method overwritten by 'quantmod':
##   method           from
##   as.zoo.data.frame zoo

adf.test(premio10_ts)      # H0: NÃO é estacionária

##
## Augmented Dickey-Fuller Test
##
## data:  premio10_ts
## Dickey-Fuller = -1.9859, Lag order = 5, p-value = 0.5821
## alternative hypothesis: stationary

ndiffs(premio10_ts)        # usa KPSS -> H0 oposta: É estacionária

## [1] 0

# ACHADO (contradição reveladora):
# - ADF: p=0,58 -> não rejeita H0 -> "parece NÃO-estacionária".
# - ndiffs: 0 -> "não precisa diferenciar" (diferenciar = olhar a variação
# de um mês pro outro, em vez do valor absoluto).
# Eles divergem porque têm hipóteses nulas OPOSTAS e cada um falhou em
# rejeitar a sua. A série é BORDERLINE – quase raiz unitária (= não tem um
# nível fixo pra onde voltar; vai ficando onde o último empurrão deixou...
# por exemplo, a temperatura de uma cidade tende a orbitar uma média;
# já nossa situação é como o saldo de uma conta, que parte
# sempre do último valor e não desfaz os movimentos passados).
# Faz sentido: o juro real é limitado (não vai a infinito), mas em 15 anos se
# comporta quase como passeio aleatório (= cada valor é o anterior + um
# empurrão aleatório, então prever pra onde vai é quase impossível).


# --- Diferenciando: a variação mês a mês resolve? ---

```

```
# A série original vagava (não-estacionária), e isso é um problema: o ARIMA  
# precisa de uma série estável pra modelar. A saída é DIFERENCIAR – em vez do  
# valor cheio de cada mês (6,7%, 7,0%...), passar a olhar a VARIAÇÃO de um  
# mês  
# pro outro (+0,2, -0,1, +0,4...). Esses valores ficam sempre perto de zero,  
# então não "vagam" como os valores cheios. Aqui testamos se diferenciar UMA  
# vez já resolve.  
dif1 <- diff(premio10_ts)
```

```
# Gráfico: antes a série passeava entre 3% e 7%; agora oscila em torno de  
# ZERO e sempre volta pra lá. Cara de série estável.
```


```
autoplot(dif1) +  
  labs(title = "Prêmio 10 anos – 1ª diferença", x = NULL, y = NULL) +  
  theme_minimal()
```



```
# ACF: na série original ela caía devagar (a tal "memória Longa"); agora  
# DESPENCA – só o lag 1 se destaca, o resto entra nas bandas. A persistência  
# sumiu.
```

```
acf(dif1)
```

Series dif1



```
# ADF:  $p=0,01$  -> agora REJEITA "não-estacionária" -> a série diferenciada É  
# estacionária, com confiança estatística.
```

```
adf.test(dif1)
```

```
## Warning in adf.test(dif1): p-value smaller than printed p-value
```

```
##
```

```
## Augmented Dickey-Fuller Test
```

```
##
```

```
## data: dif1
```

```
## Dickey-Fuller = -4.3779, Lag order = 5, p-value = 0.01
```

```
## alternative hypothesis: stationary
```

```
# ACHADO: diferenciar uma vez resolveu. A série da VARIAÇÃO mensal é estável,  
# então é nela que os modelos vão trabalhar (o "d=1" do ARIMA, mais à frente,  
# é exatamente isso: o modelo diferenciando a série por dentro).
```

```
# --- PACF: rumo às ordens do ARIMA ---
```

```
# PACF da série diferenciada: ajuda a estimar quantos termos AR o modelo
```

```
# precisa. A regra é contar quantos "palitos" furam a linha azul no começo -
```


```
# aqui só o lag 1 fura, sugerindo ~1 termo AR. Junto com a ACF (que apontava
```

```
# ~1 termo MA), o palpite manual fica perto de ARIMA(1,1,1) - bem na
```

```
vizinhança
```

```
# do que o auto.arima vai escolher sozinho na próxima seção.
```

```
pacf(dif1)
```



7. MODELANDO O FUTURO (séries temporais)

--- Ajuste automático na série inteira ---

Deixamos o `auto.arima` escolher sozinho a melhor combinação de termos.

```
mod_auto <- auto.arima(premio10_ts, seasonal = FALSE)
```

```
summary(mod_auto)
```

```
## Series: premio10_ts
```

```
## ARIMA(1,0,2) with non-zero mean
```

```
##
```

```
## Coefficients:
```

```
##          ar1      ma1      ma2      mean
```

```
##          0.9603  0.2796  0.1452  5.7074
```

```
## s.e.   0.0206  0.0732  0.0787  0.5893
```

```
##
```

```
## sigma^2 = 0.0626: log likelihood = -5.93
```

```
## AIC=21.86   AICc=22.19   BIC=38.04
```

```
##
```

```
## Training set error measures:
```


```
##              ME      RMSE      MAE      MPE      MAPE      MASE
```

```
## Training set -0.00520934 0.2475212 0.1851235 -0.379786 3.727177 0.1799189
```

```
##              ACF1
```

```
## Training set 0.007207401
```

```
checkresiduals(mod_auto) # Ljung-Box: testa se sobrou padrão nos resíduos
```



```
##
##  Ljung-Box test
##
## data:  Residuals from ARIMA(1,0,2) with non-zero mean
## Q* = 18.661, df = 21, p-value = 0.6069
##
## Model df: 3.    Total lags used: 24

# (H0: resíduos são ruído aleatório, sem estrutura)
# ACHADO: o modelo escolhido foi ARIMA(1,0,2). Curioso que ele NÃO
diferenciou
# (o "0" do meio), apesar de termos visto que a série vaga. Em vez disso, pôs
# um ar1 = 0,96 (quase 1) – um termo que "puxa" cada mês quase totalmente do
# anterior, o que na prática imita o efeito de diferenciar. É o caráter
# borderline de novo: a série está no limiar, e o modelo lidou com isso por
# outro caminho.
# E os resíduos? O Ljung-Box deu p=0,61 (>0,05): NÃO rejeitamos "resíduos
# aleatórios" -> o modelo capturou a estrutura da série, não sobrou padrão.
# Confirmação no gráfico: a ACF dos resíduos fica dentro das bandas. Modelo
OK.

# --- Validação: separando treino e teste ---
# PREVISÃO fora da amostra: treino até dez/2024, teste = 2025 (12 meses).
treino <- window(premio10_ts, end = c(2024, 12))
teste  <- window(premio10_ts, start = c(2025, 1))
```

```

# ARIMA reescolhido SÓ com o treino (até dez/2024).
mod_auto_tr <- auto.arima(treino, seasonal = FALSE)
summary(mod_auto_tr)

## Series: treino
## ARIMA(1,1,0)
##
## Coefficients:
##          ar1
##          0.2677
## s.e.    0.0730
##
## sigma^2 = 0.06504: log likelihood = -8.73
## AIC=21.47   AICc=21.54   BIC=27.8
##
## Training set error measures:
##              ME          RMSE          MAE          MPE          MAPE
MASE
## Training set 0.003015342 0.2535748 0.1890058 -0.05228778 3.839902
0.1862236
##              ACF1
## Training set -0.009076257

prev_auto <- forecast(mod_auto_tr, h = length(teste))
# ACHADO (a virada): com a série INTEIRA (seção 7), o auto.arima tinha
# escolhido d=0 (não diferenciar). Agora, vendo só o treino, ele escolhe
# ARIMA(1,1,0) -> d=1, decide DIFERENCIAR. O MESMO método mudou de ideia só
# por enxergar uma amostra um pouco menor. Isso não é defeito: é a prova
# concreta de que a série está no LIMIAR entre estável e "vaga" – tão em cima
# do muro que basta tirar 2025 pra resposta virar.

# --- Concorrente manual: ARIMA(1,1,1) ---
# E se a gente montar um ARIMA na mão, em vez de aceitar o automático?
# Testamos o (1,1,1) – o palpite que a ACF+PACF sugeriram Lá atrás – pra ver
# se um modelo um pouco mais rico se sai diferente.
mod_d1 <- Arima(treino, order = c(1, 1, 1))
summary(mod_d1)


## Series: treino
## ARIMA(1,1,1)
##
## Coefficients:
##          ar1          ma1
##          0.3665   -0.1058
## s.e.    0.2306    0.2436
##
## sigma^2 = 0.06534: log likelihood = -8.64
## AIC=23.28   AICc=23.42   BIC=32.77
##
## Training set error measures:

```

```
##                                ME      RMSE      MAE      MPE      MAPE
MASE
## Training set 0.003030462 0.2534362 0.1887762 -0.04565613 3.840174
0.1859974
##                                ACF1
## Training set -0.0005874377

prev_d1 <- forecast(mod_d1, h = length(teste))
# ACHADO: deu quase no mesmo. O termo extra do (1,1,1) é a parte "MA", que
usa
# os ERROS de previsão dos meses anteriores pra corrigir o palpite atual.
Aqui
# esse termo (ma1 = -0,11) saiu minúsculo e não-significativo (erro-padrão
# maior que o próprio coeficiente -> o efeito pode ser zero), e os erros de
# treino ficaram idênticos aos do automático. Na prática, o (1,1,1) manual e
o
# (1,1,0) automático são o mesmo modelo – sinal de robustez: dois caminhos
# diferentes chegam ao mesmo lugar.

# --- A previsão do ARIMA vs o real ---
autoplot(prev_auto) +
  autolayer(teste, series = "Real") +
  labs(title = "ARIMA automático vs real (2025)", x = NULL, y = "% a.a.") +
  theme_minimal()
```



ACHADO: a previsão central (linha escura) é quase uma RETA em ~7,2 – a série

```

# é tão persistente que o melhor palpite é "o futuro parece o último valor".
0
# real de 2025 (laranja) fica colado nela: foi um ano de juro "de lado".
# Mas repare no LEQUE azul que abre: são as faixas de 80% e 95% de confiança.
# O modelo não promete 7,2 cravado – ele diz que em 12 meses o valor pode
estar
# em qualquer lugar entre ~5 e ~9. Quanto mais longe projeta, mais largo o
# leque: o modelo admitindo que sabe cada vez menos. Coerente com a série
# quase-passeio-aleatório, e um lembrete honesto de que "acertar" aqui é, em
# parte, mérito de 2025 ter ficado dentro dessa faixa larga.

```

```

# --- Concorrentes de suavização exponencial ---
mod_holt <- holt(treino, h = length(teste))
mod_ets <- forecast(ets(treino), h = length(teste))
prev_holt <- mod_holt
prev_ets <- mod_ets

```

```

# 8. QUEM PREVÊ MELHOR? (comparação por MAE no teste de 2025)

```

```

# --- Tabela de erros (MAE) ---
comp <- tibble(
  data = seq(as.Date("2025-01-01"), by = "month", length.out =
length(teste)),
  Real = as.numeric(teste),
  ARIMA = as.numeric(prev_auto$mean),
  Holt = as.numeric(prev_holt$mean),
  ETS = as.numeric(prev_ets$mean)
)

```

```

eam <- function(yreal, yprev) mean(abs(yreal - yprev))

```

```

resultados <- tibble(
  Modelo = c("ARIMA(1,1,0)", "Holt", "ETS"),
  MAE = c(eam(comp$Real, comp$ARIMA),
    eam(comp$Real, comp$Holt),
    eam(comp$Real, comp$ETS))
) %>% arrange(MAE)
resultados

```

```

## # A tibble: 3 × 2
##   Modelo      MAE
##   <chr>      <dbl>
## 1 ARIMA(1,1,0) 0.181
## 2 ETS          0.301
## 3 Holt         0.672

```

```


# ACHADO (ranking): ARIMA 0,18 < ETS 0,30 < Holt 0,67.
# - ARIMA venceu por ser HUMILDE: projeta o último nível (~7,2), e como 2025
# ficou de lado, acertou.
# - HOLT foi o PIOR porque EXTRAPOLA a tendência: pegou a alta de 2023-24 e

```

```
# projetou a série continuando a subir – mas ela estancou, e ele foi se
# descolando do real mês a mês.
# - ETS ficou no meio: também sobe, mas de forma amortecida (menos agressivo
# que o Holt), então erra menos que ele e mais que o ARIMA.
```

```
# --- Visualização: real vs todas as previsões ---
```

```
comp %>%
  pivot_longer(-data, names_to = "serie", values_to = "valor") %>%
  ggplot(aes(data, valor, color = serie)) +
  geom_line(linewidth = 0.7) +
  labs(title = "Real vs previsões – teste 2025",
       x = NULL, y = "% a.a.", color = NULL) +
  theme_minimal() + theme(legend.position = "bottom")
```



```
# O gráfico mostra com os olhos o que o MAE mediu: o HOLT (azul) dispara em
# diagonal, indo a ~8,7 enquanto o real ficou perto de 7,3 – o erro de quem
# apostou na tendência. O ETS (verde) sobe igual, mas mais devagar. O ARIMA
# (vermelho) é a linha quase plana em ~7,2, ignorando os zigue-zagues do
# real,
# mas orbitando o nível certo. O Real (roxo) serpenteia sem direção: 2025 de
# lado. Detalhe honesto: NINGUÉM capturou os solavancos do real – o ARIMA
# venceu por ser uma reta na ALTURA certa, não por adivinhar os movimentos.
```

```
# 9. A IDEIA ORIGINAL: a inclinação ajuda? (regressão concorrente)
```

```
# --- O modelo de regressão ---
```

```
analise_tr <- analise %>% filter(data <= as.Date("2024-12-01"))
```

```

analise_te <- analise %>% filter(data >= as.Date("2025-01-01"))

mod_reg <- lm(premio_10 ~ selic + ipca + cambio + inclinacao, data =
analise_tr)
summary(mod_reg)

##
## Call:
## lm(formula = premio_10 ~ selic + ipca + cambio + inclinacao,
##     data = analise_tr)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.46652 -0.32243 -0.04762  0.34950  1.45210
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.926756   0.291262  13.482  < 2e-16 ***
## selic        2.172947   0.259972   8.358 4.13e-14 ***
## ipca         0.136004   0.129111   1.053  0.294
## cambio      -0.009558   0.033081  -0.289  0.773
## inclinacao  -0.769231   0.118689  -6.481 1.25e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5765 on 149 degrees of freedom
## (22 observations deleted due to missingness)
## Multiple R-squared:  0.7269, Adjusted R-squared:  0.7196
## F-statistic: 99.16 on 4 and 149 DF, p-value: < 2.2e-16

library(car)

## Loading required package: carData

##
## Attaching package: 'car'

## The following object is masked from 'package:dplyr':
##
##      recode

## The following object is masked from 'package:purrr':
##
##      some

Anova(mod_reg)

## Anova Table (Type II tests)
##
## Response: premio_10
##           Sum Sq Df F value    Pr(>F)

```

```
## selic      23.217    1 69.8624 4.133e-14 ***
## ipca       0.369    1  1.1096   0.2939
## cambio     0.028    1  0.0835   0.7730
## inclinacao 13.959    1 42.0040 1.255e-09 ***
## Residuals  49.515 149
```

```
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# ACHADO (a resposta à pergunta central):
```

```
# - inclinacao: coef = -0,77, e no Anova é a 2ª variável mais forte (F=42),  
# atrás só da Selic. A intuição original estava certa: a forma da curva  
# carrega informação sobre o nível. O sinal negativo bate com a leitura  
# (curva inverte <-> juro alto). IMPORTANTE: o p-valor cru ( $p \approx 0$ ) é  
otimista,
```

```
# porque os resíduos são autocorrelacionados (vamos ver já abaixo) – mas a  
# relação SOBREVIVE nas variações (-0,38), e é esse o apoio robusto de que  
# ela é real, não só o p-valor.
```

```
# - selic: coef = +2,17, F=70 -> a força dominante, como esperado.
```

```
# - ipca e cambio: não-significativos EM NÍVEL. Faz sentido económico: o  
prêmio
```


```
# já é juro REAL (descontada a inflação), então o ipca spot não agrega; e o  
# efeito do câmbio provavelmente já vem embutido na Selic. (Lembrar: em  
# VARIAÇÕES o câmbio apareceu com 0,42 – a regressão em nível não pega esse  
# efeito de curto prazo.)
```

```
# -  $R^2$  ajustado = 0,72: bom ajuste.
```


```
# --- Diagnóstico dos resíduos (e o teste que importa) ---
```

```
# Os 4 gráficos clássicos parecem OK...
```

```
par(mfrow = c(2, 2)); plot(mod_reg); par(mfrow = c(1, 1))
```



...mas eles NÃO testam autocorrelação, o pressuposto que mais falha em
série temporal. Rodamos o teste certo (o mesmo do exercício 5):
checkresiduals(mod_reg)



```
##
## Breusch-Godfrey test for serial correlation of order up to 10
##
## data: Residuals
## LM test = 115.58, df = 10, p-value < 2.2e-16

# ACHADO DECISIVO: Breusch-Godfrey  $p < 2e-16$  -> autocorrelação FORTÍSSIMA, e
# dá pra VER isso no gráfico: os resíduos (painel de cima) fazem ondas
# longas,
# meses seguidos do mesmo sinal, em vez de pular aleatoriamente em torno de
# zero; e a ACF (painel de baixo) decai devagar, com vários lags fora das
# bandas – a "memória" que sobrou e o modelo não capturou.
# O que isso significa: a regressão acerta a relação CONTEMPORÂNEA (no mesmo
# mês, Selic e inclinação explicam bem o prêmio), mas viola a independência
# dos
# resíduos por ignorar a dinâmica temporal. CONSEQUÊNCIA HONESTA: sob
# autocorrelação, os erros-padrão do OLS são subestimados, então os p-valores
# da regressão são otimistas (menos confiáveis do que parecem). A relação da
# inclinação é grande e econômica, mas a PRECISÃO estatística é menor que o
# " $p \approx 0$ " sugere – e é exatamente a lacuna que a família ARIMA existe para
# preencher.

# --- A previsão de 2025 (e o veredito) ---
prev_reg <- predict(mod_reg, newdata = analyse_te)
eam(analise_te$premio_10, prev_reg)

## [1] 0.6805638
```

ACHADO FINAL: MAE da regressão = 0,68 – empatada com o PIOR modelo (Holt) e
3,7x pior que o ARIMA (0,18). O modelo mais rico em variáveis ($R^2=0,72$,
inclinação relevante) PREVÊ PIOR que um ARIMA que só olha o passado da
série.
POR QUÊ esse paradoxo? Porque explicar e prever são coisas diferentes:
(1) a regressão é estática – fotografa a relação de um mês, mas ignora a
dinâmica temporal (foi o que a autocorrelação dos resíduos denunciou),
então erra em sequência ao projetar;
(2) a regressão ainda jogou COM VANTAGEM: para prever 2025 ela usou os
valores REAIS de Selic/IPCA/câmbio/inclinação de 2025 – informação
que,
na vida real, você não teria de antemão (teria que prevê-los antes). E
mesmo com essa vantagem, perdeu pro ARIMA.
EXPLICAR != PREVER: um bom ajuste no passado não garante boa previsão no
futuro.
RESSALVA: ARIMA e regressão tiveram treinos um pouco diferentes (a
regressão
perdeu 22 meses pelos buracos do premio_20). Mas o teste (2025) é idêntico
e a
margem do ARIMA é grande demais (3,7x) para isso explicar o resultado.

PARTE III – CONCLUSÃO
#####

10. CONCLUSÃO

FECHANDO O ARCO: a pergunta que abriu o trabalho era se a forma da curva
(a inclinação) ajuda a entender o juro de 10 anos. A resposta tem duas
camadas: SIM para EXPLICAR (a inclinação é a 2ª variável mais forte na
regressão, e a relação sobrevive até nas variações), mas isso NÃO se
converteu em previsão melhor – o ARIMA simples ganhou. A inclinação é
informativa sobre o presente; não é uma bola de cristal sobre o futuro.

MORAL TÉCNICA: para prever este juro real, um ARIMA simples (que só usa o
passado da própria série) bateu uma regressão cheia de variáveis macro. Em
uma série quase-passeio-aleatório e "de lado" no teste, a humildade venceu.

MORAL ECONÔMICA (leitura da curva, com o devido ceticismo):
- ROBUSTO (medição): dez/2025 é um extremo histórico da amostra – juro real
no topo e curva fortemente invertida; e a inclinação tem associação real,
ainda que modesta, com o nível do juro.
- INTERPRETAÇÃO (hipótese, não fato): a curva invertida é lida como o
mercado esperando que o juro alto não perdure. Isso supõe a hipótese das
expectativas e ignora o prêmio de prazo.
- LIMITE: a própria modelagem mostra que o nível futuro é largamente
imprevisível. Portanto, a curva informa uma EXPECTATIVA do mercado, não
um

destino. O que os dados sustentam com segurança é apenas que estamos num
ponto extremo e incomum – não uma previsão confiável sobre para onde vai.